


AetherFloat 架構之免區塊縮放 (Block-Scale-Free)

四進位浮點數 AI 硬體加速器設計


LLM的算力需求與低位元轉型

- 現代深度學習應用的運算與儲存成本顯著增加。
- 低位元量化：使用較窄位元的資料格式（如 FP8、INT8）已成為降低成本的關鍵。



Introduction to MX Format

- **Block-Scaling:** 多個數值共用一個 scale factor
- 在「硬體效率」、「模型準確度」之間取得平衡



Hardware Bottlenecks of MX

- LLM的activation layer 容易產生outlier
- Outlier 導致同區塊內較小數值被強制量化為零。
- 依賴動態區塊縮放（AMAX），需要額外電路，且會導致 pipeline stall。

AetherFloat 架構簡介

- 一種免區塊縮放 (Block-Scale-Free) 浮點數架構。
- 消除AMAX 邏輯與相關的硬體與管線開銷。
- 結合 Lexicographic One's Complement Unpacking、Quad-Radix (Base-4) Scaling 與 Explicit Mantissa。

Quad-Radix Scaling

- 將 Exponent 的底數由 Base-2 替換為 Base-4
- 不需動態 AMAX 硬體

	Base-2 (FP8 E4M3)	Quad-Radix Base-4 (AF8)
Dynamic Range	10^{-2} to 448	1.22×10^{-4} to 57,344
Alignment Logic	Deep Barrel Shifters	Shallow 2-stage MUX
Block-Scaling	Required	Eliminated

Lexicographic One's Complement Unpacking

- 捨棄傳統 Sign-Magnitude，對負數的 Magnitude 位元執行 One's Complement (Bitwise inversion)。
- 操作僅需單個 XOR，無 Carry-propagation 邏輯。
- 使浮點數具備原生 Signed-integer 的單調遞增排序特性。

Explicit Mantissa & Unified Datapath

- 捨棄 IEEE 754 隱藏前導位元，Mantissa 採完全 Explicit（顯式）儲存。
- 犧牲1-bit 的數學精度，將 Multiplier array由傳統的 4x4 bit 縮減至 3x3 bit。
- 當 $\text{Exponent} = 0$ 時，硬體直接暫停，無須切換電路。